



Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΑΡΧΙΤΕΚΤΟΝΙΚΕΣ 5G, ΤΕΧΝΟΛΟΓΙΕΣ,
ΕΦΑΡΜΟΓΕΣ, ΚΑΙ ΒΑΣΙΚΟΙ ΔΕΙΚΤΕΣ
ΑΠΟΔΟΣΗΣ

Αναφορά Project: ΘΕΜΑ 10

ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2024-2025

Μαράκη Ελένη . AM 1084534 . 5^ο Έτος

Code Repository Link:

[https://github.com/ElinaMaraki/5G Project](https://github.com/ElinaMaraki/5G_Project)

Σκοπός

Σκοπός της εργασίας είναι η ομαδοποίηση Quality of Service δεδομένων σε ένα 5G δίκτυο και η συσχέτιση των ομάδων αυτών σε διαφορετικούς τύπους 5G εφαρμογών.

Αναλυτικότερα, εφαρμόζοντας διαφορετικές τεχνικές clustering, ομαδοποιούμε εγγραφές από ένα σύνολο QoS δεδομένων ως προς τα χαρακτηριστικά τους. Από την ομαδοποίηση αυτή, στόχος είναι να παρατηρηθεί συνάφεια μεταξύ διαφορετικών τύπων εφαρμογών σε ένα 5G δίκτυο.

Δεδομένα

Το σύνολο δεδομένων έχει μορφή πίνακα, αποτελείται δηλαδή από γραμμές και στήλες και περιέχει 400 εγγραφές. Κάθε εγγραφή αντιστοιχεί σε μία σύνδεση στο 5G δίκτυο. Οι εγγραφές αυτές έχουν καταγραφεί σε χρονικό διάστημα 6 λεπτών. Κάθε εγγραφή διαθέτει τα παρακάτω χαρακτηριστικά:

- **Timestamp:** Datetime κάθε εγγραφής που καλύπτει την κίνηση του δικτύου για 6 λεπτά. (Type: DateTime)
- **User_ID:** Το αναγνωριστικό κάθε χρήστη του οποίου οι πληροφορίες ανακτώνται στο δίκτυο. (Type: String)
- **Application_type:** Ο τύπος της εφαρμογής που χρησιμοποιεί κάθε χρήστης του δικτύου. (Type: String)
- **Signal Strength:** Το επίπεδο ισχύος που λαμβάνει η συσκευή του χρήστη από έναν πύργο κυψέλης (dBm). (Type: String)
- **Latency:** Χρόνος που χρειάζεται για να ταξιδέψουν οι πληροφορίες από την πηγή στον προορισμό, σε χιλιοστά του δευτερολέπτου (ms). Ο χαμηλός λανθάνων χρόνος είναι ζωτικής σημασίας για εφαρμογές σε πραγματικό χρόνο, όπως τα διαδικτυακά παιχνίδια, η τηλεδιάσκεψη και τα αυτόνομα οχήματα. (Type: String)
- **Required_Bandwidth:** Η ποσότητα της χωρητικότητας δεδομένων που απαιτείται για την υποστήριξη μιας συγκεκριμένης υπηρεσίας ή εφαρμογής χωρίς υποβάθμιση της απόδοσης. Τυπικά σε megabits ανά δευτερόλεπτο (Mbps) ή gigabits ανά δευτερόλεπτο (Gbps). (Type: String)
- **Allocated_Bandwidth:** Το μέγεθος της χωρητικότητας δεδομένων που κατανέμεται για την κάλυψη της συγκεκριμένης υπηρεσίας ή εφαρμογής που απαιτείται, διασφαλίζοντας ότι δεν υπάρχει υποβάθμιση της απόδοσης. Τυπικά σε megabits ανά δευτερόλεπτο (Mbps) ή gigabits ανά δευτερόλεπτο (Gbps). (Type: String)

- **Resource Allocation:** Η δυναμική κατανομή των πόρων του δικτύου —όπως το εύρος ζώνης, η ισχύς και οι χρονοθυρίδες— μεταξύ διαφόρων χρηστών και υπηρεσιών για τη βελτιστοποίηση της απόδοσης και τη διασφάλιση της Ποιότητας Υπηρεσίας (QoS). (Type: String)

Προεπεξεργασία

Η προεπεξεργασία των δεδομένων αποτελεί το πρώτο στάδιο της διαδικασίας. Στόχος της είναι η βελτίωση της ποιότητας και της δομής των δεδομένων, ώστε να διασφαλιστεί η αποδοτικότητα των αλγορίθμων ομαδοποίησης, αποτρέποντας σφάλματα, καθώς και η παραγωγή αξιόπιστων αποτελεσμάτων.


Στο πλαίσιο της παρούσας υλοποίησης η προεπεξεργασία των δεδομένων προσφέρει οργάνωση του συνόλου δεδομένων, αφαιρώντας άχρηστες για την ομαδοποίηση πληροφορίες, κανονικοποίηση των ποσοτικών χαρακτηριστικών για την αποδοτικότερη ανάλυσή τους, καθώς και αποκάλυψη εσωτερικών συσχετίσεων μεταξύ των χαρακτηριστικών που βοηθούν στη σωστή εφαρμογή των αλγορίθμων.

Δεδομένου ότι το αρχικό σύνολο αποτελείται κυρίως από μεταβλητές τύπου string (με εξαίρεση το πεδίο Timestamp, το οποίο είναι τύπου datetime), κρίθηκε αναγκαία η μετατροπή τους σε ποσοτικές μεταβλητές. Αρχικά, διασφαλίστηκε η ομοιομορφία των μονάδων μέτρησης ανά στήλη και αφαιρέθηκαν οι μονάδες από τις τιμές των χαρακτηριστικών, μετατρέποντας τα δεδομένα σε καθαρά αριθμητικές μεταβλητές.

Πιο συγκεκριμένα, για τα πεδία 'Required_Bandwidth' και 'Allocated_Bandwidth', όλες οι εγγραφές μετατράπηκαν σε κοινή μονάδα μέτρησης — kilobits ανά δευτερόλεπτο (kbps). Αφαιρέθηκαν οι λεκτικές ενδείξεις των μονάδων από τις τιμές και οι στήλες μετατράπηκαν σε τύπο float. Αντίστοιχα, τα πεδία 'Resource_Allocation' και 'Signal_Strength' μετατράπηκαν σε τύπο int, και το 'Latency' σε float.

Οι μεταβλητές 'User_ID' και 'Timestamp' καθώς και 'Application_Type' δεν περιέχουν χρήσιμη πληροφορία για την ομαδοποίηση των τύπων εφαρμογών ως προς τα χαρακτηριστικά τους. Επομένως, αφαιρέθηκαν από το σύνολο δεδομένων.

Η ομαδοποίηση των διαφορετικών τύπων εφαρμογών θα γίνει με βάση την ομοιότητα των χαρακτηριστικών τους. Δηλαδή, τις «κοντινές» τιμές των ποσοτικών μεταβλητών. Σημαντικό παράγοντα παρουσιάζει και η συσχέτιση των μεταβλητών αυτών. Για την οπτικοποίηση της συσχέτισης μεταξύ των χαρακτηριστικών υλοποιήθηκε



heatmap. Από αυτό παρατηρείται ότι τιμές κοντά στο 1 αναδεικνύουν θετική συσχέτιση, κοντά στο -1 αρνητική(/αντίθετη) συσχέτιση, ενώ κοντά στο 0 καμία συσχέτιση. Από αυτό παρατηρείται ότι υπάρχει άμεση συσχέτιση μεταξύ του απαιτούμενου εύρους ζώνης και του κατανεμημένου εύρους ζώνης. Όσο αυξάνεται η απαίτηση σε εύρος ζώνης, τόσο αυξάνεται και η κατανομή του. Δεν παρατηρείται συσχέτιση μεταξύ της καθυστέρησης (latency) και του απαιτούμενου ή κατανεμημένου εύρους ζώνης και υπάρχει αρνητική συσχέτιση μεταξύ της καθυστέρησης και της κατανομής πόρων, δηλαδή όσο αυξάνεται η κατανομή πόρων, τόσο μειώνεται η καθυστέρηση.

Οι ποσοτικές μεταβλητές έχουν πολύ διαφορετικές μονάδες μέτρησης (ms, Mbps, ποσοστά), με συνέπεια να εμφανίζουν μεγάλη απόκλιση στα εύρη τιμών των στηλών.

Αλγόριθμοι όπως ο K-means, που θα αναλυθεί παρακάτω, παρουσιάζουν ευαισθησία/bias σε ακραίες τιμές. Για την διασφάλιση λοιπόν αξιοπιστών αποτελεσμάτων ακολούθησε κανονικοποίηση σε z-scores. Με τον τρόπο αυτό όλες οι μεταβλητές αποκτούν μέση τιμή 0 και τυπική απόκλιση 1. Η τεχνική κανονικοποίησης z-score είναι προτιμότερη στο συγκεκριμένο πρόβλημα έναντι άλλων, όπως Min-Max Scaling καθώς είναι λιγότερο επιρρεπής σε ακραίες τιμές. Αυτό είναι λογικό διότι δεν αναπροσαρμόζονται όλες οι τιμές με βάση της μέγιστης και της ελάχιστης τιμής, αλλά επιτρέπει μεγάλο εύρος τιμών ανάλογα με την απόκλιση από τον μέσο όρο.

Ο τύπος που ακολουθεί η κανονικοποίηση Z-score

$$Z - score = \frac{X - \mu}{\sigma}$$

Όπου

X: αρχική τιμή μεταβλητής

μ: μέση τιμή μεταβλητής

σ: τυπική απόκλιση μεταβλητής

Για την υλοποίηση χρησιμοποιήθηκε η εξίσωση StandardScaler της βιβλιοθήκης sklearn.

Αλγόριθμοι Ομαδοποίησης

Για την υλοποίηση της ομαδοποίησης χρησιμοποιήθηκαν δύο τεχνικές μηχανικής μάθησης ο αλγόριθμος K-means και ο ιεραρχικός αλγόριθμος με Ward's linkage method και μία τεχνική βαθιάς μάθησης Self-Organizing Map.

Οι αλγόριθμοι ομαδοποίησης βασίζονται στην αρχή ότι η νοημοσύνη αντανακλάται στην ικανότητα αναγνώρισης και ομαδοποίησης όμοιων αντικειμένων. Οι αλγόριθμοι αυτοί ανήκουν στην κατηγορία μη επιβλεπόμενης μάθησης. Σε αντίθεση με την επιβλεπόμενη μάθηση, όπου το σύστημα εκπαιδεύεται με δεδομένα εισόδου και τις αντίστοιχες επιθυμητές εξόδους, η μη επιβλεπόμενη μάθηση εστιάζει στην ανάλυση και ερμηνεία δεδομένων χωρίς

τη χρήση προκαθορισμένων ετικετών ή κατηγοριών. Επιδιώκει να ανακαλύψει υποκείμενες δομές, πρότυπα και σχέσεις μέσα στα ίδια τα δεδομένα.

Με βάση της δυνατότητας ενός αντικειμένου να ανήκει σε ακριβώς μία κλάση ή παραπάνω από μία, οι αλγόριθμοι ομαδοποίησης χωρίζονται σε Hard και Soft clustering αντίστοιχα.

Ακόμα, με βάση των χαρακτηριστικών τους διακρίνονται σε διάφορες κατηγορίες όπως Partition Based, Hierarchical, Density Based, Grid Based και Model Based. Οι αλγόριθμοι που υλοποιήθηκαν ανήκουν στις δύο πρώτες κατηγορίες.

Οι Partition Based αλγόριθμοι δημιουργούν μη επικαλυπτόμενες κλάσεις, όπου τα κέντρα των δεδομένων αποτελούν και κέντρα των αντίστοιχων κλάσεων. Οι αλγόριθμοι αυτοί έχουν προκαθορισμένο αριθμό κλάσεων, μικρή χρονική πολυπλοκότητα και υψηλή υπολογιστική αποτελεσματικότητα. Οι αλγόριθμοι αυτοί είναι ευαίσθητοι σε ακραίες τιμές και είναι εύκολο να εγκλωβιστούν σε τοπικά βέλτιστα. Για τον λόγο αυτό οι partition based αλγόριθμοι δεν αποδίδουν καλά σε μη-κυρτά δεδομένα.

Ο αλγόριθμος ομαδοποίησης K-means ανήκει στην κατηγορία hard clustering partition based αλγορίθμων. Δεδομένου ενός προκαθορισμένου πλήθους κλάσεων στόχος του είναι να εντοπίσει τα κέντρα (centroids) των K αυτών κλάσεων, έτσι ώστε να ελαχιστοποιηθεί η ενδοομαδική απόσταση. Κάθε κλάση αναπαρίσταται μέσω ενός μέσου διανύσματος, που είναι ο αριθμητικός μέσος των σημείων που ανήκουν σε αυτή. Ο αλγόριθμος ξεκινά με τυχαία αρχικοποίηση των K κέντρων και στη συνέχεια εκτελεί επαναληπτικά τα εξής βήματα. Κάθε σημείο δεδομένων ανατίθεται στη κλάση του πλησιέστερου κέντρου βάσει ευκλείδειας απόστασης και υπολογίζεται εκ νέου το κέντρο κάθε συστάδας ως ο μέσος των σημείων που ανήκουν σε αυτή. Η λήξη της επαναληπτικής αυτής διαδικασίας μπορεί να γίνει με κριτήριο είτε ότι τα κέντρα δεν αλλάζουν, είτε ότι τα σημεία δεν αλλάζουν κλάση, είτε ότι έχει συμπληρωθεί ο προκαθορισμένος αριθμός επαναλήψεων. Ο K-Means είναι απλός, αποδοτικός και επαναληπτικός αλγόριθμος, όμως επηρεάζεται από την αρχική επιλογή κέντρων και δεν εγγυάται το βέλτιστο παγκόσμιο ελάχιστο.

Οι Hierarchical based αλγόριθμοι ομαδοποίησης προϋποθέτουν την δημιουργία και ανάλυση δένδρογραμματος για την εύρεση του βέλτιστου πλήθους κλάσεων. Το δένδρογράμμα αυτό σε κάθε επίπεδο έχει ένα πιθανό συνδυασμό κλάσεων, με το πλήθος των αντικειμένων κάθε κλάσης να αυξάνεται όσο περνάς τα επίπεδα. Η κατασκευή του δένδρογραμματος μπορεί να ξεκινήσει είτε από το ανώτερο επίπεδο, στο οποίο όλα τα αντικείμενα ανήκουν σε μία ενιαία κλάση και σταδιακά διαχωρίζονται σε υποκλάσεις, είτε από το κατώτερο επίπεδο, όπου κάθε αντικείμενο αποτελεί ξεχωριστή κλάση και οι κλάσεις συγχωνεύονται μεταξύ τους καθώς ανεβαίνουμε στην ιεραρχία. Η υλοποίηση με την πρώτη τεχνική ονομάζεται “top-down” προσέγγιση και οι αλγόριθμοι αυτοί ονομάζονται divisive, ενώ η δεύτερη προσέγγιση ονομάζεται “bottom-up” και οι αντίστοιχοι αλγόριθμοι agglomerative. Παράδειγμα της πρώτης προσέγγισης αποτελεί ο hierarchical k-means αλγόριθμος, ο οποίος ξεκινάει με μία κλάση η οποία περιέχει όλα τα αντικείμενα και σε κάθε επανάληψη διαχωρίζει μία κλάση. Σε αυτού του τύπου αλγορίθμους αντικείμενα τα οποία είναι κοντά και θα μπορούσαν να

ανήκουν στην ίδια κλάση, λόγω κάποιου αρχικού διαχωρισμού καταλήγουν σε διαφορετικές. Στην bottom-up προσέγγιση η ένωση των κλάσεων γίνεται με χρήση μετρικών απόστασης, επιλέγοντας σε κάθε επανάληψη το πιο κοντινό ζεύγος κλάσεων για ένωση. Μερικές από τις μετρικές που χρησιμοποιούνται για τον υπολογισμό της απόστασης μεταξύ δύο κλάσεων είναι η Nearest Neighbor (/Single Linkage), βάση της οποίας η απόσταση μεταξύ δύο κλάσεων ορίζεται ως η ελάχιστη Ευκλείδεια απόσταση μεταξύ οποιανδήποτε δύο σημείων τους, η Complete Linkage η οποία ορίζει την απόσταση αυτή ως την μέγιστη απόσταση μεταξύ οποιονδήποτε δύο σημείων των κλάσεων και αντίστοιχα η Average Linkage ορίζει την απόσταση μεταξύ δυο κλάσεων ως την μέση απόσταση μεταξύ οποιανδήποτε δύο σημείων τους. Σε κάθε επανάληψη ενώνονται οι κλάσεις με την ελάχιστη Single, Complete και Average απόσταση αντίστοιχα. Ακόμα η μετρική Centroid Method θεωρεί ότι η απόσταση μεταξύ δύο κλάσεων ταυτίζεται με την απόσταση των κέντρων τους και η Ward's Linkage Method στην οποία για κάθε πιθανή συγχώνευση στο τρέχον επίπεδο, εκτιμάται το νέο κέντρο στην κλάση και υπολογίζεται το άθροισμα των τετραγωνικών αποκλίσεων όλων των σημείων της από το νέο κέντρο. Στη συνέχεια, συγκρίνεται η απόκλιση με την τρέχουσα απόκλιση και επιλέγεται η συγχώνευση με την μικρότερη διαφορά απόκλισης από την τρέχουσα. Οι αλγόριθμοι αυτοί παρουσιάζουν ποικιλομορφία στο μέγεθος και σχήματα των κλάσεων, εντατικό υπολογισμό, υψηλότερη χρονική πολυπλοκότητα και είναι ευαίσθητοι στον θόρυβο και τις ακραίες τιμές.

Για την ομαδοποίηση δεδομένων μπορούν να χρησιμοποιηθούν και αλγόριθμοι βαθιάς μάθησης. Στη μηχανική μάθηση, οι αλγόριθμοι εκπαιδεύονται σε μεγάλα σύνολα δεδομένων με σκοπό να εντοπίζουν μοτίβα και σχέσεις. Στη συνέχεια, χρησιμοποιούν αυτές τις γνώσεις για να κάνουν προβλέψεις ή να λαμβάνουν αποφάσεις σχετικά με νέα δεδομένα. Αντίθετα, η βαθιά μάθηση βασίζεται σε τεχνητά νευρωνικά δίκτυα με πολλαπλά επίπεδα (layers), τα οποία μπορούν να εντοπίζουν και να αναλύουν πολύ πιο σύνθετα και αφηρημένα μοτίβα στα δεδομένα. Αυτή η προσέγγιση επιτρέπει την εξαγωγή πιο ακριβών και βαθύτερων χαρακτηριστικών, γεγονός που την καθιστά ιδιαίτερα αποτελεσματική σε σύνθετα προβλήματα.

Μία μέθοδος βαθιάς μάθησης είναι το Self-Organizing Map, που προτάθηκε από τον Teuvo Kohonen. Το SOM ή αλλιώς δίκτυο Kohonen αποτελείται από το επίπεδο εισόδου και από ένα επίπεδο υπολογιστικών νευρώνων (επίπεδο Kohonen) και κάνει τοπογραφική απεικόνιση της εισόδου στο μεγάλης διάστασης επίπεδο εξόδου. Στηρίζεται στην αρχή του σχηματισμού τοπογραφικού χάρτη (principle of topographic map formation) βάση της οποίας η θέση ενός νευρώνα εξόδου σε έναν τοπογραφικό χάρτη αντιστοιχεί σε ένα συγκεκριμένο χαρακτηριστικό του προτύπου εισόδου. Πιο συγκεκριμένα, αποτελείται από ένα πλέγμα νευρώνων (δίκτυο), όπου κάθε νευρώνας σχετίζεται με ένα διάνυσμα βαρών ίδιων διαστάσεων με τα δεδομένα εισόδου. Οι συνδέσεις από τους νευρώνες εισόδου προς τους νευρώνες του επιπέδου Kohonen ονομάζονται προς τα εμπρός (forward) και αυτές μεταξύ των νευρώνων του επιπέδου εξόδου ονομάζονται παράπλευρες (lateral).

Τα δίκτυα Kohonen μπορούν να χαρακτηριστούν ως ανταγωνιστικά, αλλά και συνεργατικά. Ανήκουν στην κατηγορία ανταγωνιστικής μάθησης (competitive learning), στην οποία σε αντίθεση με άλλα είδη μάθησης, όπου μπορούν να ενεργοποιούνται ταυτόχρονα

περισσότεροι του ενός νευρώνες, οι νευρώνες ανταγωνίζονται μεταξύ τους για το ποιος θα ενεργοποιηθεί καθώς μόνο ένας μπορεί να είναι ενεργός κάθε φορά. Ο νευρώνας αυτός που κερδίζει ονομάζεται “winner-takes-all neuron”. Αλλά βασίζεται και στην ιδέα της γειτονιάς, όπου οι νευρώνες που ανήκουν στην γειτονιά του νικητή νευρώνα κερδίζουν και αυτοί (cooperative).

Στο δίκτυο Kohonen ένας νευρώνας μαθαίνει μετατοπίζοντας τα βάρη του, από τις μη ενεργές συνδέσεις προς τις ενεργές. Μόνο ο νικητής νευρώνας και η γειτονιά του έχουν το δικαίωμα να μαθαίνουν. Εάν ένας νευρώνας δεν ανταποκρίνεται στο δείγμα στην είσοδο, τότε δεν μπορεί να «μάθει». Η έξοδος του νικητή νευρώνα είναι ίση με το 1 και όλων των υπολοίπων με το 0.

Κατά την εκπαίδευση ενός δικτύου Kohonen ξεκινάμε με μια γειτονιά μεγάλου μεγέθους και όσο προχωρά η διαδικασία της εκπαίδευσης, το μέγεθος της γειτονιάς μικραίνει. Αυτό γίνεται με την συνάρτηση Mexican Hat όπου οι τιμές των βαρών των παράπλευρων συνδέσεων συναρτήσει της απόστασης των νευρώνων από τον νικητή. Οι παράπλευρες συνδέσεις χρησιμοποιούνται για να δημιουργήσουν τον ανταγωνισμό μεταξύ των νευρώνων του επιπέδου Kohonen. Η κοντινή γειτονιά του νικητή νευρώνα έχει ισχυρή διεγερτική επίδραση, η απομακρυσμένη γειτονιά έχει μια ήπια ανασταλτική επίδραση και η πολύ απομακρυσμένη γειτονιά έχει μια αδύναμη διεγερτική επίδραση που συνήθως αγνοείται.

Τα βήματα που ακολουθούνται είναι τα εξής:

- 1) Αρχικοποίηση Βαρών είτε τυχαία, είτε με σταθερές τιμές, για παρόμοια αποτελέσματα σε πολλαπλές επαναλήψεις.
- 2) Ενεργοποίηση με το διάνυσμα εισόδου

$$j_x(p) = \min_j \|x - w_j(p)\| = \left\{ \sum_{i=1}^N [x_i - w_{ji}]^2 \right\}^{1/2}$$

- 3) Εκπαίδευση / Ενημέρωση βαρών του νικητή και των γειτονικών νευρώνων

$$w_{ji}(p+1) = w_{ji} + \Delta w_{ji}(p),$$

$$\Delta w_{ji}(p) = \begin{cases} a(x_i - w_{ji}(p)), & j \in \Lambda_j(p) \\ 0, & j \notin \Lambda_j(p) \end{cases}$$

Η Ενημέρωση Ρυθμού Μάθησης γίνεται με τον τύπο:

$$a(p) = a(0)(1 - p/P),$$

Όπου, p: current iteration , P: total number of iterations

Και ο ορισμός της γειτονιάς με Gaussian Συνάρτηση

$$\Lambda_{ij} = \exp \left(- \frac{d_{ij}^2}{2\sigma(p)^2} \right)$$

Τα βάρη του νικητή και των γειτόνων του ενημερώνονται προς την κατεύθυνση του διανύσματος εισόδου X :

$$W_j(p+1) = W_j(p) + a(p)\Lambda_{ij}(p)(X - w_j(p))$$

Βέλτιστο Πλήθος Κλάσεων

Για καθένα από τα μοντέλα αυτά σημαντικό βήμα είναι η επιλογή του βέλτιστου πλήθους κλάσεων.

Υπάρχουν διάφοροι μέθοδοι για τον υπολογισμό του βέλτιστου αυτού πλήθους.


Η Elbow Method βασίζεται στο άθροισμα τετραγωνικών σφαλμάτων εντός των κλάσεων (Within-Cluster Sum of Squares – WCSS).

$$WCSS(K) = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

Όπου, C_j το κέντρο της κλάσης και x_i κάθε σημείο της κλάσης.

Η μέθοδος αυτή τρέχει τον αλγόριθμο ομαδοποίησης για διαφορετικά πλήθη κλάσεων και για καθένα από αυτά υπολογίζει το WCSS. Όσο το πλήθος των κλάσεων αυξάνεται, το WCSS μειώνεται, καθώς κάθε κλάση περιέχει λιγότερα στοιχεία. Η βελτίωση αυτή όμως γίνεται φθίνουσα, έως ότου η μείωση του WCSS παύει να είναι σημαντική και η αύξηση του πλήθους των κλάσεων δεν έχει πλέον νόημα. Το σημείο αυτό ονομάζεται “Elbow” στην γραφική της καμπύλης WCSS ως προς το πλήθος των κλάσεων K . Ο βέλτιστος αριθμός κλάσεων, λοιπόν, επιλέγεται ως το K στο σημείο που σχηματίζεται το elbow.

Σε αλγορίθμους που δεν είναι κεντροειδής όπως για παράδειγμα ο ιεραρχικός το WCSS δεν έχει πλέον νόημα. Άρα πρέπει να χρησιμοποιηθεί διαφορετική μετρική. Για την προσαρμογή στον ιεραρχικό αλγόριθμο χρησιμοποιήθηκε η ward’s linkage.



Μία άλλη μέθοδος για την αξιολόγηση της ομαδοποίησης είναι ο C-index. Με αυτή την μέθοδο η αυτός ο αλγόριθμος για κάθε κλάση υπολογίζει το άθροισμα των αποστάσεων μεταξύ όλων των σημείων της κλάσης και τις συγκρίνει με τις ελάχιστες και μέγιστες δυνατές αποστάσεις στο σύνολο δεδομένων.

$$Cindex = \frac{S - S_{min}}{S_{max} - S_{min}}$$

Όπου,

S: Το άθροισμα των πραγματικών αποστάσεων μεταξύ όλων των ζευγών σημείων που ανήκουν στην ίδια κλάση.

n: ο αριθμός το ζεύγων που υπάρχουν σε κάθε κλάση

S_{min} : Το άθροισμα των n μικρότερων αποστάσεων που μπορούν να βρεθούν στο σύνολο του dataset.

S_{max} : Το άθροισμα των n μεγαλύτερων αποστάσεων που μπορούν να βρεθούν στο σύνολο του dataset.

Το C-index παίρνει τιμές από 0 έως 1.

Εάν οι αποστάσεις μεταξύ των σημείων που ανήκουν στην ίδια κλάση είναι σημαντικά μικρότερες από τις αποστάσεις με σημεία άλλων κλάσεων, τότε η ομαδοποίηση θεωρείται επιτυχής. Άρα όσο πιο κοντά είναι ο C-index στο 0, τόσο καλύτερη είναι η ομαδοποίηση.

Μία ακόμη ευρέως χρησιμοποιούμενη μέθοδος για την αξιολόγηση της ποιότητας της ομαδοποίησης είναι η Silhouette Scoring.

Ο Silhouette Score μετρά το πόσο καλά ταιριάζει κάθε σημείο με τη δική του συστάδα σε σύγκριση με τις γειτονικές συστάδες, παρέχοντας τιμές στο διάστημα [-1, 1]. Όσο πιο κοντά στο +1 είναι η τιμή, τόσο καλύτερη είναι η ομαδοποίηση.

Υπολογίζει πόσο καλά διαχωρισμένες είναι οι κλάσεις. Για ένα μόνο σημείο το silhouette score υπολογίζεται ως η διαφορά μεταξύ της μέσης απόστασης του σημείου από τα υπόλοιπα σημεία της ίδιας κλάσης (α) και της μέσης απόστασης από το σημείο δεδομένων σε σημεία στην πλησιέστερη γειτονική συστάδα (β), διαιρούμενη με το μέγιστο των α και β.

$$S(i) = \frac{b(i) - a(i)}{\max \{a(i) - b(i)\}}$$

Ο δείκτης Silhouette παίρνει τιμές από -1 έως 1. Όσο πιο κοντά βρίσκεται η τιμή στο +1, τόσο καλύτερα είναι διαχωρισμένες οι κλάσεις και τόσο πιο σωστά φαίνεται να έχει ταξινομηθεί το εκάστοτε σημείο στη δική του κλάση και απέχει σημαντικά από τις γειτονικές κλάσεις (περίπτωση όπου η ενδοσυσταδική απόσταση α είναι μικρότερη από τη μικρότερη απόσταση από άλλη συστάδα b, δηλαδή α < b). Αντίθετα, όταν ο δείκτης είναι κοντά στο 0, σημαίνει ότι οι κλάσεις επικαλύπτονται και το σημείο βρίσκεται περίπου το ίδιο κοντά σε

δύο ή περισσότερες κλάσεις ($a \approx b$). Τέλος, εάν η τιμή του silhouette score είναι κοντά στο -1 δείχνει πιθανή λανθασμένη ταξινόμηση του σημείου, αφού βρίσκεται πλησιέστερα σε άλλη συστάδα από αυτή που του έχει αποδοθεί ($a > b$). Ο συνολικός δείκτης Silhouette για ένα σύνολο δεδομένων υπολογίζεται ως ο μέσος όρος όλων των επιμέρους δεικτών Silhouette των σημείων, προσφέροντας μία συνολική εικόνα της ποιότητας της ομαδοποίησης.


Υλοποίηση

Για τον υπολογισμό του βέλτιστου αριθμού κλάσεων πρέπει να συνυπολογισθεί και η φύση του προβλήματος. Στην συγκεκριμένη υλοποίηση όπου σκοπός είναι να βρεθούν ομοιότητες μεταξύ των application types οι κλάσεις θα πρέπει να είναι τουλάχιστον μικρότερες από το πλήθος των διαφορετικών application types στο σύνολο δεδομένων. Το συγκεκριμένο σύνολο περιέχει 11 τύπους εφαρμογών.


Για τον αλγόριθμο K-means χρησιμοποιήθηκαν οι τεχνικές Elbow Method και C-index.

Για τον Kmeans αλγόριθμο χρησιμοποιήθηκε η συνάρτηση KMeans της βιβλιοθήκης sklearn, η οποία παράγει και τα WCSS, ενώ για τον υπολογισμό του C-index υλοποιήθηκε επαναληπτική συνάρτηση η οποία υπολογίζει τις αποστάσεις των ζευγών και επιστρέφει τον C-index του K-means για διαφορετικά πλήθη κλάσεων.


Με την πρώτη μέθοδο ο βέλτιστος αριθμός κλάσεων υπολογίστηκε να είναι 5 ενώ με την δεύτερη 10.





Όπως φαίνεται και από τα PCA, οι κλάσεις είναι πολλές για το σύνολο δεδομένων που έχουμε και για τους μόνο 11 διαφορετικούς τύπους εφαρμογών. Επομένως το βέλτιστο πλήθος κλάσεων για τον K-means αλγόριθμο ορίστηκε ως $K=5$.




Για τον ιεραρχικό αλγόριθμο αρχικά υλοποιήθηκε το δενδρόγραμμα με την χρήση της βιβλιοθήκης `scipy`.



Και χρησιμοποιήθηκαν οι τεχνικές Elbow και Silhouette Scoring για την εύρεση του βέλτιστου αριθμού κλάσεων.




Με την πρώτη μέθοδο ο βέλτιστος αριθμός κλάσεων υπολογίστηκε ως 3 ενώ με την δεύτερη 9. Λόγω της φύσης του προβλήματος και του συνόλου δεδομένων, το βέλτιστο πλήθος κλάσεων για τον ιεραρχικό αλγόριθμο επιλέχθηκε ίσο με 3.




Τέλος για την μέθοδο βαθιάς μάθησης SOM καθώς πρόκειται για ένα τετραγωνικό πλέγμα και το πλήθος των μοναδικών τύπων εφαρμογών είναι 11 τα πιθανά πληθι κλάσεων ήταν περιορισμένα. Στην περίπτωση 1x1 πλέγματος το οποίο θα περιέχει μόνο 2 κλάσεις η πληροφορία για την ομαδοποίηση των τύπων εφαρμογών θα ήταν πολύ γενική. Αντίθετα στην περίπτωση 3x3 πλέγματος οι 9 κλάσεις είναι πολλές για την ομαδοποίηση των 11 τύπων εφαρμογών και τα μεγαλύτερα πλέγματα θα εμφανίσουν παραπάνω κλάσεις από ότι μοναδικοί τύποι εφαρμογών. Οπότε για τον SOM επιλέχθηκε πλήθος κλάσεων $K=4$ για 2x2 πλέγμα.

Αποτελέσματα


K-means PCA, $K=5$



Hierarchical Ward's Linkage PCA, K=3



SOM PCA, K=4



Εξετάζοντας τα αποτελέσματα των αλγορίθμων μπορεί να διαπιστωθεί ότι οι κατηγορίες που ομαδοποιούνται μαζί πιο συχνά είναι οι Streaming – Online Gaming – VoIP Call καθώς και IoT Temperature - Background download - Video Streaming. Παρότι υπάρχει συνοχή μεταξύ των ομαδοποιήσεων και των τριών αλγορίθμων τα αποτελέσματά τους δεν είναι ίδια. Η ομαδοποίηση και με τις 3 μεθόδους είναι επιτυχής χωρίς να παρουσιάζεται κάποια βέλτιστη ομαδοποίηση.


Application_Type	Signal_Strength	Latency	Required_Bandwidth	Allocated_Bandwidth	Resource_Allocation
Background_Download	-104.06	56.98	547.87	548.94	60.11
IoT_Temperature	-100.23	102.15	3.85	5.15	70.38
Web_Browsing	-99.79	15.56	487.50	487.50	69.69
Video_Streaming	-93.94	38.85	2938.30	3314.89	70.32
Streaming	-89.62	41.85	3353.19	3893.62	84.47
Voice_Call	-80.00	20.00	100.00	120.00	80.00
VoIP_Call	-75.78	31.30	81.63	104.13	89.89
File_Download	-75.00	45.00	2000.00	2000.00	70.00
Video_Call	-62.40	32.88	11814.66	13284.05	74.48
Online_Gaming	-62.16	29.11	4140.00	4455.56	80.00
Emergency_Service	-53.83	5.57	678.72	744.68	70.64

Παρακάτω φαίνεται αναλυτικά η ομαδοποίηση των διαφορετικών τύπων εφαρμογών και με τις 3 μεθόδους.

Clustering Method	Cluster	Application Types	Cluster Characteristics
KMEANS	0	Web Browsing, Video Streaming, File Download	Low Signal Strength, Mid Required/ Allocated Bandwidth, Mid to Low Resource Allocation
	1	Video Call	Mid to High Signal Strength, Mid Latency/ Resource Allocation, Very High Bandwidth
	2	Streaming, VoIP Call, Online Gaming, Voice Call	Highest Resource Allocation, High Required/Allocated Bandwidth, Mid Latency
	3	Background Download, IoT Temperature, Video Streaming	Lowest Signal Strength, High Latency, Low Resource Allocation
	4	Emergency Service	High Signal Strength, Low Latency, Mid Required/Allocated Bandwidth/ Resource Allocation
HIERARCHICAL	0	Emergency Service, VoIP Call, Online Gaming, Streaming, Voice Call	Mid to High Signal Strength, Mid to High Recourse Allocation
	1	Video Call	-
	2	Web Browsing, Background Download, Video Streaming, IoT Temperature, File Download	Low Signal Strength and Resource Allocation
SOM	0	Video Call, Online Gaming	High Signal Strength, Mid Latency, Highest Bandwidth, Mid Resource Allocation
	1	Background Download, Video Streaming, IoT Temperature, File Download	-
	2	VoIP Call, Streaming, Online Gaming	-
	3	Web Browsing, Emergency Service, Voice Call	Low Latency, Mid to Low Bandwidth, Low Resource Allocation

Παρακάτω φαίνονται οι διαφορετικοί τύποι εφαρμογών ταξινομημένοι ανάλογα με τις τιμές τους σε κάθε κατηγορία χαρακτηριστικών και με διαφορετικό χρώμα ανάλογα με κάθε ομάδα.

APPLICATION TYPE SORTED BY:	Signal Strength	Latency	Bandwidth	Resource Allocation
KMEANS	Emergency_Service	IoT_Temperature	Emergency_Service	Background_Download
	Online_Gaming	VoIP_Call	Web_Browsing	Web_Browsing
	Video_Call	Voice_Call	Voice_Call	File_Download
	File_Download	Web_Browsing	Online_Gaming	Video_Streaming
	VoIP_Call	Background_Download	VoIP_Call	IoT_Temperature
	Voice_Call	Emergency_Service	Video_Call	Emergency_Service
	Streaming	File_Download	Video_Streaming	Video_Call
	Video_Streaming	Video_Streaming	Streaming	Online_Gaming
	Web_Browsing	Streaming	File_Download	Voice_Call
	IoT_Temperature	Online_Gaming	Background_Download	Streaming
	Background_Download	Video_Call	IoT_Temperature	VoIP_Call
HIERARCHICAL	Emergency_Service	IoT_Temperature	Emergency_Service	Background_Download
	Online_Gaming	VoIP_Call	Web_Browsing	Web_Browsing
	Video_Call	Voice_Call	Voice_Call	File_Download
	File_Download	Web_Browsing	Online_Gaming	Video_Streaming
	VoIP_Call	Background_Download	VoIP_Call	IoT_Temperature
	Voice_Call	Emergency_Service	Video_Call	Emergency_Service
	Streaming	File_Download	Video_Streaming	Video_Call
	Video_Streaming	Video_Streaming	Streaming	Online_Gaming
	Web_Browsing	Streaming	File_Download	Voice_Call
	IoT_Temperature	Online_Gaming	Background_Download	Streaming
	Background_Download	Video_Call	IoT_Temperature	VoIP_Call
SOM	Emergency_Service	IoT_Temperature	Emergency_Service	Background_Download
	Online_Gaming	VoIP_Call	Web_Browsing	Web_Browsing
	Video_Call	Voice_Call	Voice_Call	File_Download
	File_Download	Web_Browsing	Online_Gaming	Video_Streaming
	VoIP_Call	Background_Download	VoIP_Call	IoT_Temperature
	Voice_Call	Emergency_Service	Video_Call	Emergency_Service
	Streaming	File_Download	Video_Streaming	Video_Call
	Video_Streaming	Video_Streaming	Streaming	Online_Gaming
	Web_Browsing	Streaming	File_Download	Voice_Call
	IoT_Temperature	Online_Gaming	Background_Download	Streaming
	Background_Download	Video_Call	IoT_Temperature	VoIP_Call



Σύγκριση Αλγορίθμων

Για να συγκρίνουμε τις μεθόδους ομαδοποίησης, παρότι το πρόβλημα υλοποιήθηκε για τον βέλτιστο αριθμό κλάσεων έγινε υλοποίηση των αλγορίθμων με κοινό αριθμό κλάσεων $K=4$.

Από τα PCA παρότι η ταξινόμηση σε κλάσεις και των τριών αλγορίθμων είναι όμοια, μπορούν να παρατηρηθούν κάποιες διαφορές. Ο αλγόριθμος K-means παρότι έχει μερικώς επικαλυπτόμενες κλάσεις, είναι καλά ορισμένες. Ο ιεραρχικός αλγόριθμος από την άλλη παρουσιάζει κλάσεις οι οποίες είναι πλήρως επικαλυπτόμενες από άλλες, μειώνοντας την αξιοπιστία του. Η μέθοδος SOM παρουσιάζει μεγαλύτερου μεγέθους κλάσεις με ομοιόμορφα κατανομημένο πλήθος σημείων σε κάθε κλάση. Αν και ο διαχωρισμός δεν είναι απόλυτα σαφής όπως στον K-means, η χωρική κατανομή υποδεικνύει καλύτερη αναπαράσταση της εσωτερικής δομής των δεδομένων. Το γεγονός αυτό καθιστά τη μέθοδο SOM κατάλληλη για πολυδιάστατα ή μη γραμμικά προβλήματα.

Πιο συγκεκριμένα τα μεγέθη των κλάσεων είναι τα παρακάτω.

K-Means Μεγέθη Κλάσεων:



[139 57 126 78]

Hierarchical Μεγέθη Κλάσεων:

[156 57 142 45]

SOM Μεγέθη Κλάσεων: [76 109 120 95]

Συνοψίζοντας, ο K-means φαίνεται να υπερέχει ως προς την καθαρότητα και σαφήνεια των κλάσεων, ενώ ο SOM προσφέρει μεγαλύτερη ευελιξία και ισορροπημένη ομαδοποίηση.



Πηγές

<https://online.stat.psu.edu/stat505/lesson/14/14.4>

<https://www.geeksforgeeks.org/difference-between-machine-learning-and-deep-learning/>

<http://kaggle.com/discussions/general/527563>

<https://repository.kallipos.gr/handle/11419/9117>

<https://builtin.com/data-science/elbow-method#:~:text=The%20elbow%20method%20is%20a%20graphical%20method%20for%20finding%20the,the%20graph%20forms%20an%20elbow.>

<https://medium.com/@zalarushirajsinh07/the-elbow-method-finding-the-optimal-number-of-clusters-d297f5aeb189>

<https://arxiv.org/abs/2401.07389>

<https://www.displayr.com/what-is-dendrogram/#:~:text=A%20dendrogram%20is%20a%20diagram,to%20allocate%20objects%20to%20clusters.>

<https://medium.com/@jackieejackson/clustering-and-principal-component-analysis-pca-from-sklearn-c8ea5fed6648>

<https://ieeexplore.ieee.org/document/7973581>

<https://docs.scipy.org/doc/scipy/reference/cluster.hierarchy.html>

<https://scikit-learn.org/stable/modules/clustering.html>